SEMANA 2 · ESTADÍSTICA Y MACHINE LEARNING PARA ESTUDIANTES DE MEDICINA

Describir datos

Tipos de variables, media, mediana, dispersión y la tabla 1, con la anemia de las niñas y niños del Perú.

Dr. Niels Pacheco-Barrios · Datos: ENDES 2024, INEI

PLAN DE LAS DOS HORAS

Hoy

- **0 a 35 min.** Antes de resumir: qué es una fila, los códigos trampa y los tipos de variables. Centro y dispersión.
- **35 a 75 min.** Cuaderno en Colab, partes 0 a 5.
- **75 a 90 min.** La tabla 1: qué lleva, qué no lleva y por qué.
- **90 a 120 min.** Cuaderno, partes 6 a 8, y cierre.

Al terminar usted podrá

- Clasificar cualquier variable de una historia clínica.
- Calcular media, mediana, varianza y DE a mano con `numpy`.
- Elegir entre media (DE) y mediana [RIC].
- Construir y criticar una tabla 1.

EL PROBLEMA

43.7%

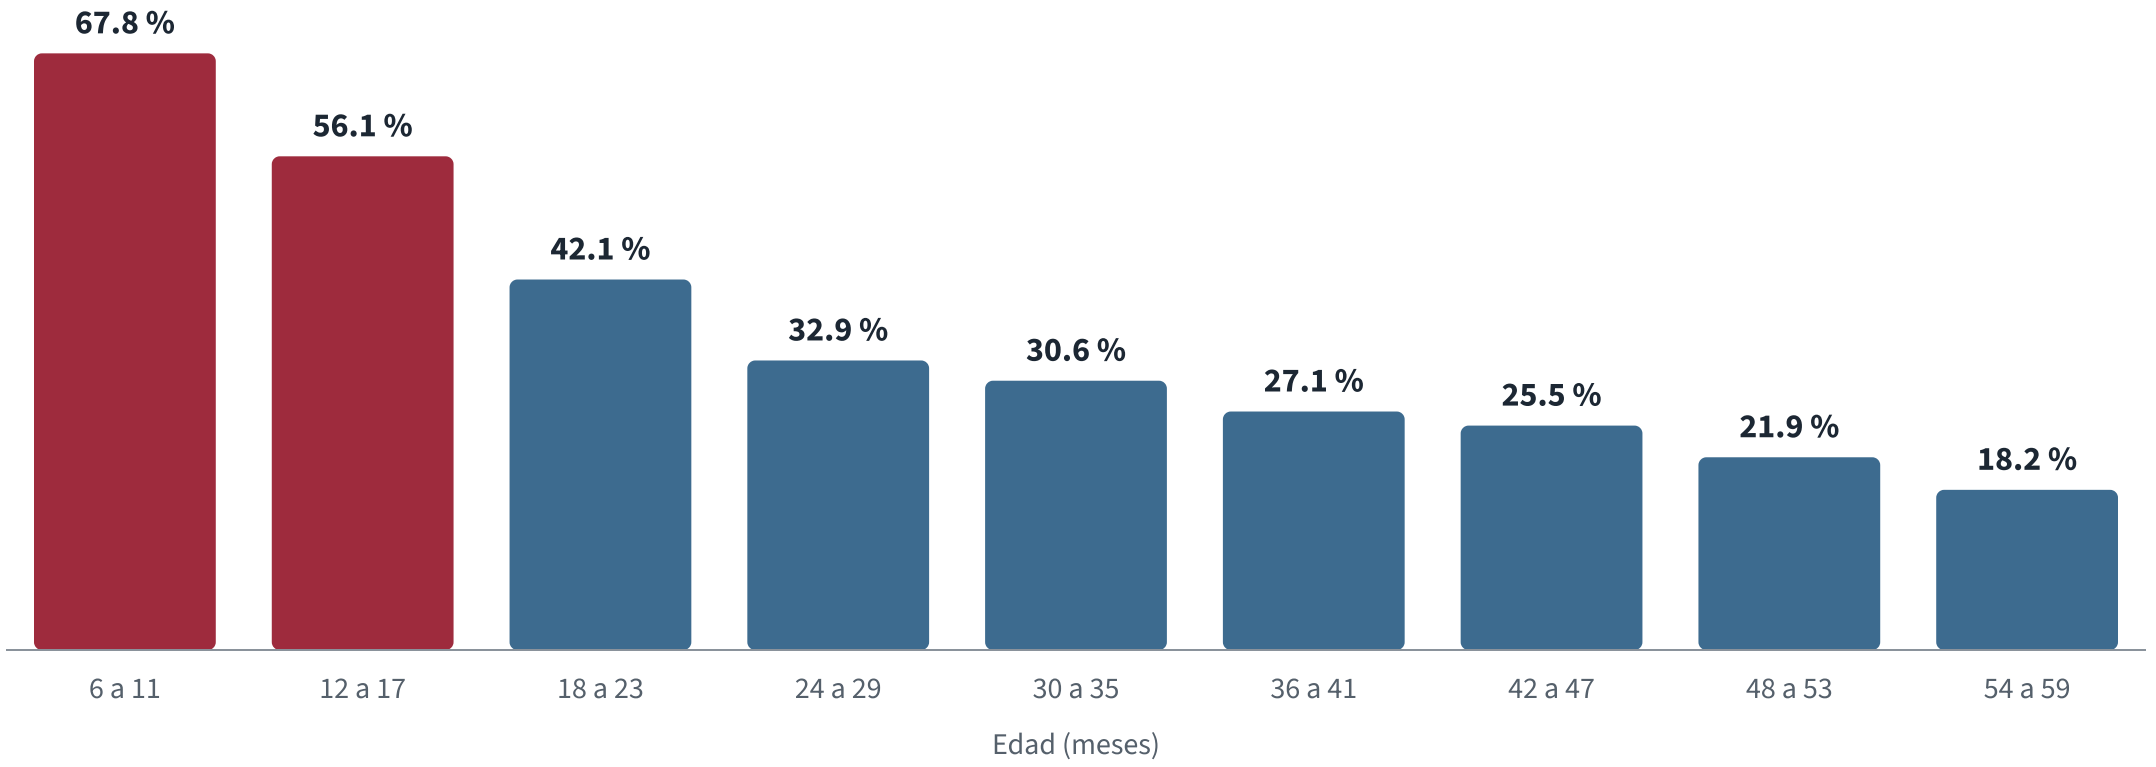
de las niñas y niños de 6 a 35 meses tenía anemia en el Perú en 2024.

Hoy usted va a llegar a este número desde los microdatos de la ENDES. Si su número coincide con el oficial, su limpieza de datos está bien hecha.

INEI. Indicadores de resultados de los programas presupuestales, ENDES 2024 (Cuadro 06, criterio RM 363-2022-MINSA).

LO QUE VAMOS A DESCRIBIR

La anemia se concentra en el primer año de vida



ENDES 2024, niños de 6 a 59 meses con hemoglobina medida (n = 18 358). Porcentajes sin ponderar.

ANÁLISIS EXPLORATORIO (EDA)

Seis preguntas antes de cualquier modelo

1

¿Qué es una fila?

Un niño, un hogar, una visita, una muestra de laboratorio.

2

¿Puedo confiar?

Códigos de faltantes, unidades, valores imposibles, duplicados.

3

¿Cómo se reparte?

Centro, dispersión y forma de cada variable.

4

¿Qué se relaciona?

Semanas 7 y 8.

5

¿Hay estructura oculta?

Subgrupos, conglomerados (semana 10).

6

¿Qué implica para el análisis?

Qué modelo, qué ajuste, qué advertir.

EL EDA CAMBIA SEGÚN EL DISEÑO

Qué describe la tabla 1 en cada tipo de estudio

Diseño	Las columnas son…	El EDA busca sobre todo…
Transversal (ENDES, NHANES)	Total y subgrupos (área, sexo)	A quién representa la muestra; pesos de muestreo
Cohorte	Expuestos y no expuestos	Diferencias al inicio que podrían confundir
Casos y controles	Casos y controles	Si los controles vienen de la misma población
Ensayo clínico	Brazos de tratamiento	Que la aleatorización produjo grupos parecidos

En todos los casos la primera tarea es la misma: entender los datos antes de compararlos.

STROBE, ítem 14 (Vandenbroucke et al., PLoS Med 2007) · CONSORT 2010, ítem 15 (Moher et al., BMJ 2010).

PARTE 1

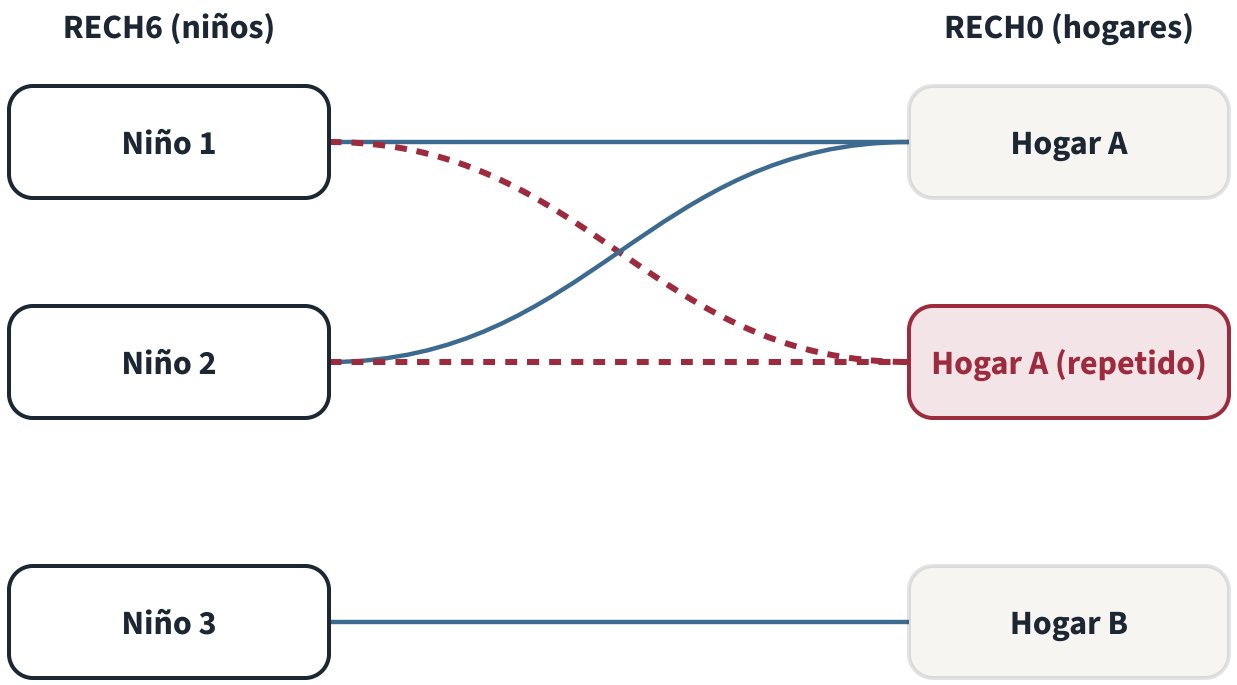
Antes de resumir

¿Qué es una fila? ¿Puedo confiar en los números?

1

PREGUNTA 1 · ¿QUÉ ES UNA FILA?

Un niño no es un hogar



3 niños se convierten en 5 filas

En `RECH6` una fila es un **niño**. En `RECH0`, un **hogar**. Para saber el área o la altitud de cada niño hay que unirlas por `HHID`.

Si un hogar aparece **dos veces** en la tabla de hogares, sus niños se duplican sin aviso.

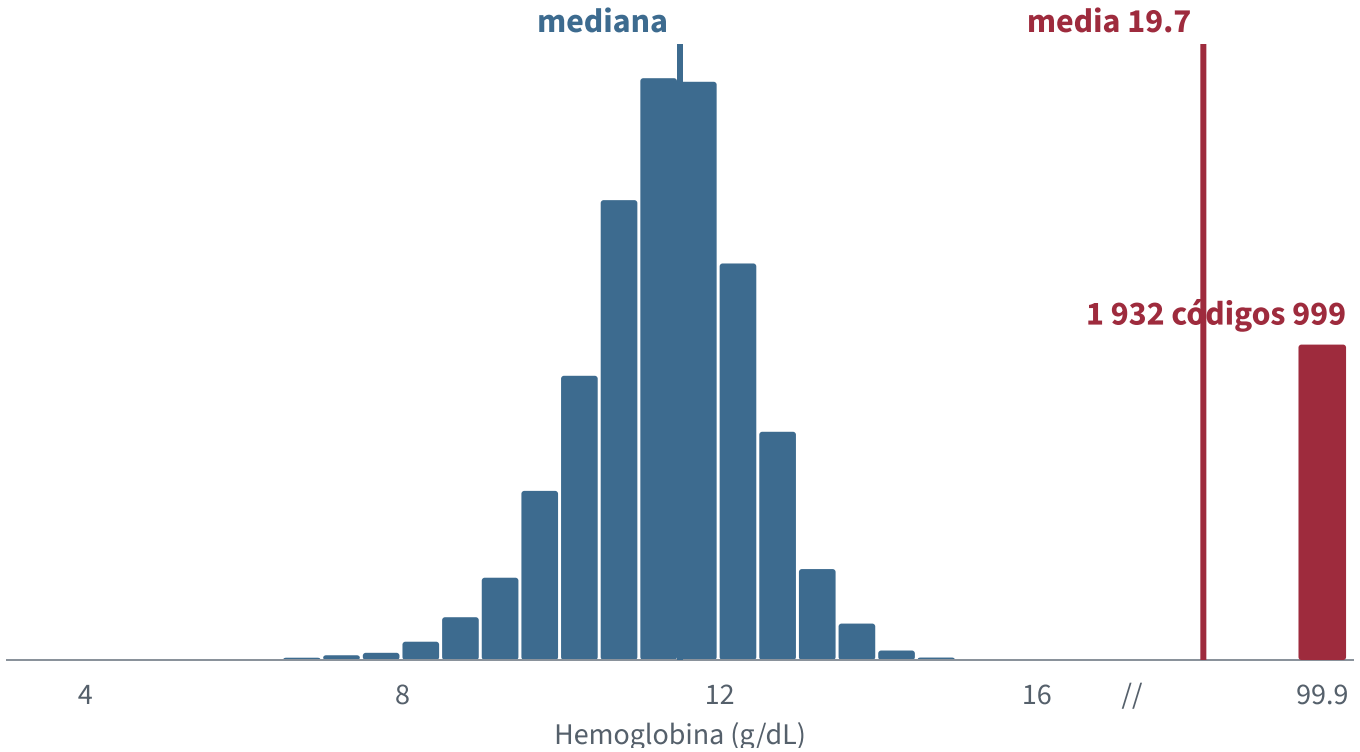
```
ninos.merge(hogar, on="HHID",
            validate="many_to_one")
```

`validate` detiene el código si la llave no es única.

ENDES 2024: 20 290 niños en 17 828 hogares; 2 314 hogares aportan dos o más niños.

PREGUNTA 2 · ¿PUEDO CONFIAR?

Una hemoglobina media de 19.7 g/dL




```
df["HC56"].describe()
count   20290
mean      197.0
50%       115.0
max       999.0
```

La ENDES escribe **999** cuando no pudo medir. Para pandas es un número más.

1 932 niños con 999 suben la media de 11.3 a **19.7 g/dL**: policitemia en todo el país.

La mediana casi no se mueve (de 11.3 a 11.5). La media es frágil.

HC56: hemoglobina ajustada por altitud, en g/dL × 10. Eje horizontal cortado entre 16 y 99.9 g/dL.

PREGUNTA 2 · ¿PUEDO CONFIAR?

Lista corta de sospechosos

- **9, 99, 999, 9999:** "no sabe", "no aplica", "no medido".
- **0 o −1** en variables que no pueden valer eso (peso, presión).
- **Fechas de relleno:** 1900-01-01, 1970-01-01.
- **Unidades mezcladas:** Hb en g/dL y g/L; talla en cm y m; glucosa en mg/dL y mmol/L.
- **Escalas ocultas:** la ENDES guarda la Hb × 10 y el puntaje z × 100.

Tres líneas que lo detectan

```
df.describe()            # mire min y max
df["x"].value_counts(dropna=False)
df.isna().sum()           # faltantes reales
```

Y una regla: lea el diccionario de variables antes de la primera media.

TIPOS DE VARIABLES

El tipo decide el resumen

Numéricas

Continua	Se mide. Hemoglobina, altitud, puntaje z de talla.
Discreta	Se cuenta. Número de hermanos, controles prenatales.

Categóricas

Nominal	Sin orden. Región natural, grupo sanguíneo.
Ordinal	Con orden. Nivel de anemia, quintil de riqueza, educación.
Binaria	Dos valores. Anemia sí/no, sexo, área urbana/rural.

Un mismo dato puede cambiar de tipo: la hemoglobina (continua) se vuelve anemia (binaria) o nivel de anemia (ordinal). Cada paso pierde información.

EJERCICIO RÁPIDO · HAGA CLIC EN CADA TARJETA

¿De qué tipo es?

Escala de coma de Glasgow

Ordinal

de 8 a 9 no equivale a de 13 a 14

Puntaje de Apgar

Ordinal

suma de 5 ítems ordinales

Grupo sanguíneo ABO

Nominal

A, B, AB, O: sin orden

Edad en meses cumplidos

Discreta

se trata como continua si hay muchos valores

Dolor en escala de 0 a 10

Ordinal

se suele promediar; hay que justificarlo

Creatinina sérica

Continua

y asimétrica: mediana [RIC]

Estadio de cáncer (I a IV)

Ordinal

el orden importa, la distancia no

Fumador actual (sí/no)

Binaria

n (%)

Hospitalizaciones en el año

Discreta

casi siempre sesgada a la derecha

PARTE 2

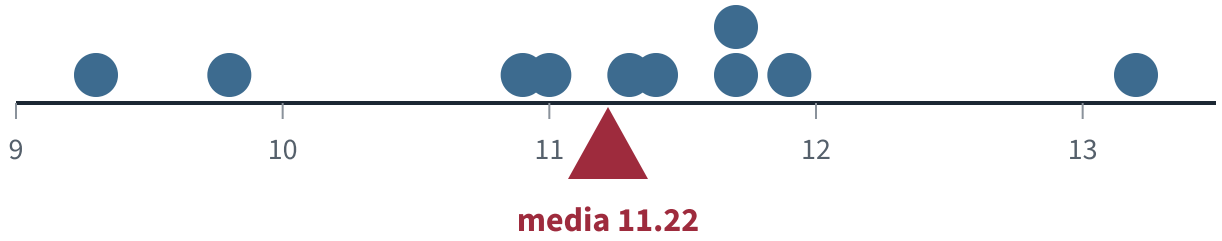
El centro

Media y mediana: qué miden y cuándo engañan.

2

LA MEDIA

La media es el punto de equilibrio



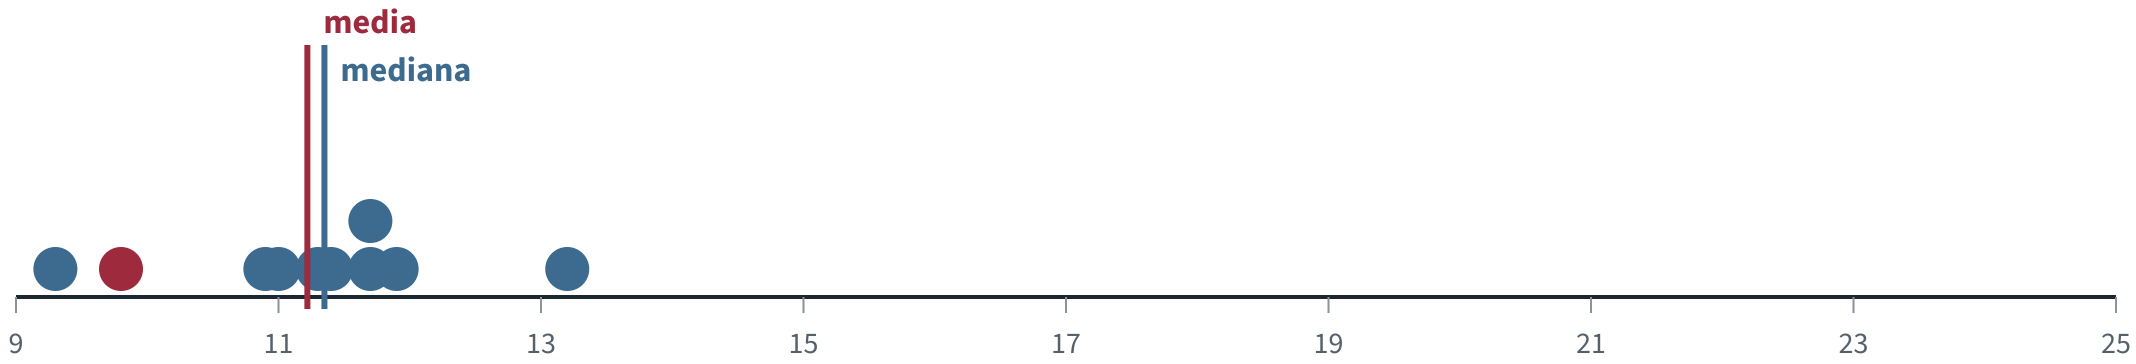
$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Diez niños de la ENDES. Si las bolitas fueran pesos sobre una regla, la regla se equilibraría en la media.

```
hb.sum() / len(hb)   # 11.22
np.mean(hb)          # 11.22
```

MEDIA CONTRA MEDIANA · ARRASTRE EL CONTROL

Un error de digitación: 115 en lugar de 11.5



Décimo valor	Media	Mediana
9.8	11.22	11.35

La mediana es el valor del medio de los datos ordenados. Solo le importa el orden, no la distancia: por eso resiste los valores extremos.

MEDIA, MEDIANA Y MODA

¿Cuál reporto?

Medida	Usa	Se mueve con extremos	Úsela para
Media	Todos los valores	Mucho	Distribuciones simétricas: Hb, talla, presión
Mediana	Solo el orden	Poco	Asimétricas: días de estancia, creatinina, altitud
Moda	La frecuencia	No aplica	Categóricas: el grupo más común

Si la media y la mediana se separan, la distribución está sesgada. Esa diferencia ya es un hallazgo.

PARTE 3

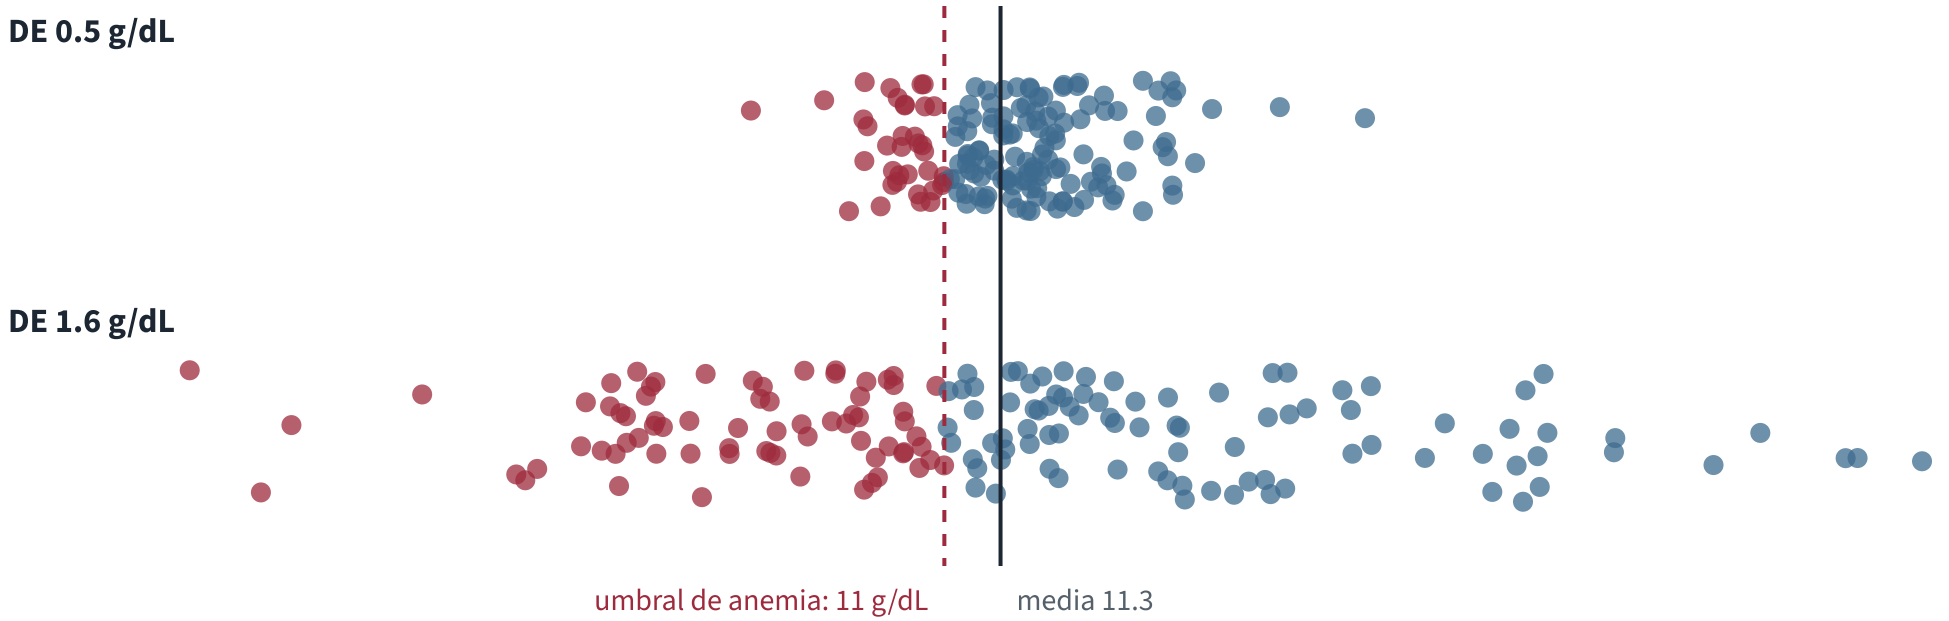
La dispersión

Varianza, desviación estándar y percentiles.

3

POR QUÉ NO BASTA CON LA MEDIA

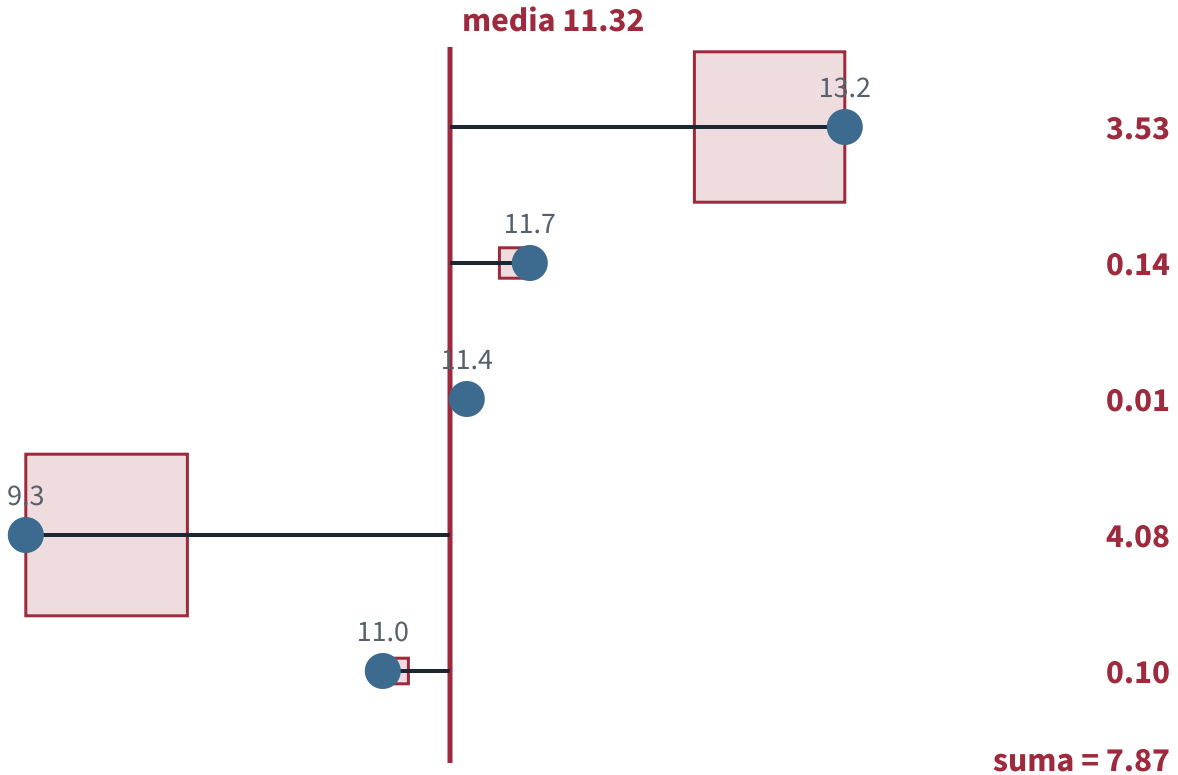
Misma media, poblaciones distintas



Las dos nubes tienen media 11.3 g/dL. En la de abajo, muchos más niños quedan por debajo de 11, el umbral de anemia. La dispersión decide cuántos enfermos hay.

LA VARIANZA PASO A PASO

Promediar distancias al cuadrado



1. Distancia de cada valor a la media (11.32).

2. Al cuadrado: así los negativos no cancelan a los positivos, y lo lejano pesa más.

3. Sumar: 7.87. Dividir entre n − 1 = 4: **varianza 1.97 (g/dL)²**.

4. Raíz cuadrada: **DE = 1.40 g/dL**, de nuevo en unidades clínicas.

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

¿POR QUÉ N − 1?

Los desvíos siempre suman cero

Si conozco la media y cuatro de los cinco desvíos, el quinto ya está decidido.

```
+1.88  +0.38  +0.08  -0.32
quinto = -2.02
```

Solo 4 desvíos son libres: **4 grados de libertad**. Dividir entre n subestima la varianza de la población; dividir entre n − 1 lo corrige.

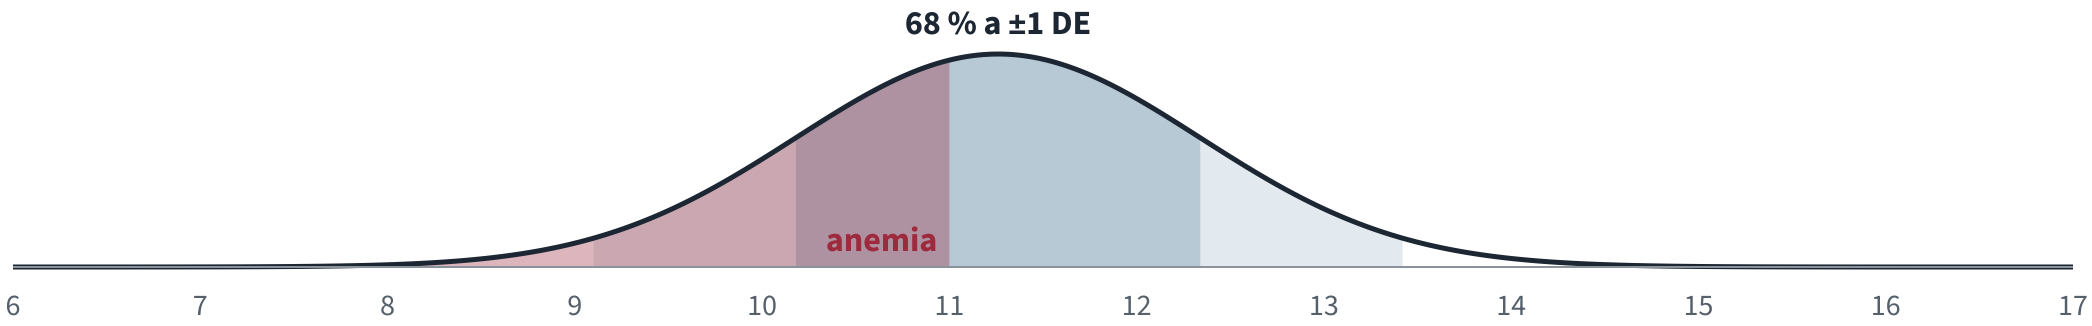
La trampa de `ddof`

```
np.std(cinco)           # 1.2544  ÷ n
np.std(cinco, ddof=1)   # 1.4025  ÷ (n-1)
pd.Series(cinco).std() # 1.4025
```

numpy divide entre n por defecto; pandas, R y SPSS, entre n − 1. Con 18 mil niños no importa; con 12 pacientes, sí.

DESVIACIÓN ESTÁNDAR · MUEVA EL CONTROL

La regla 68 · 95 · 99.7



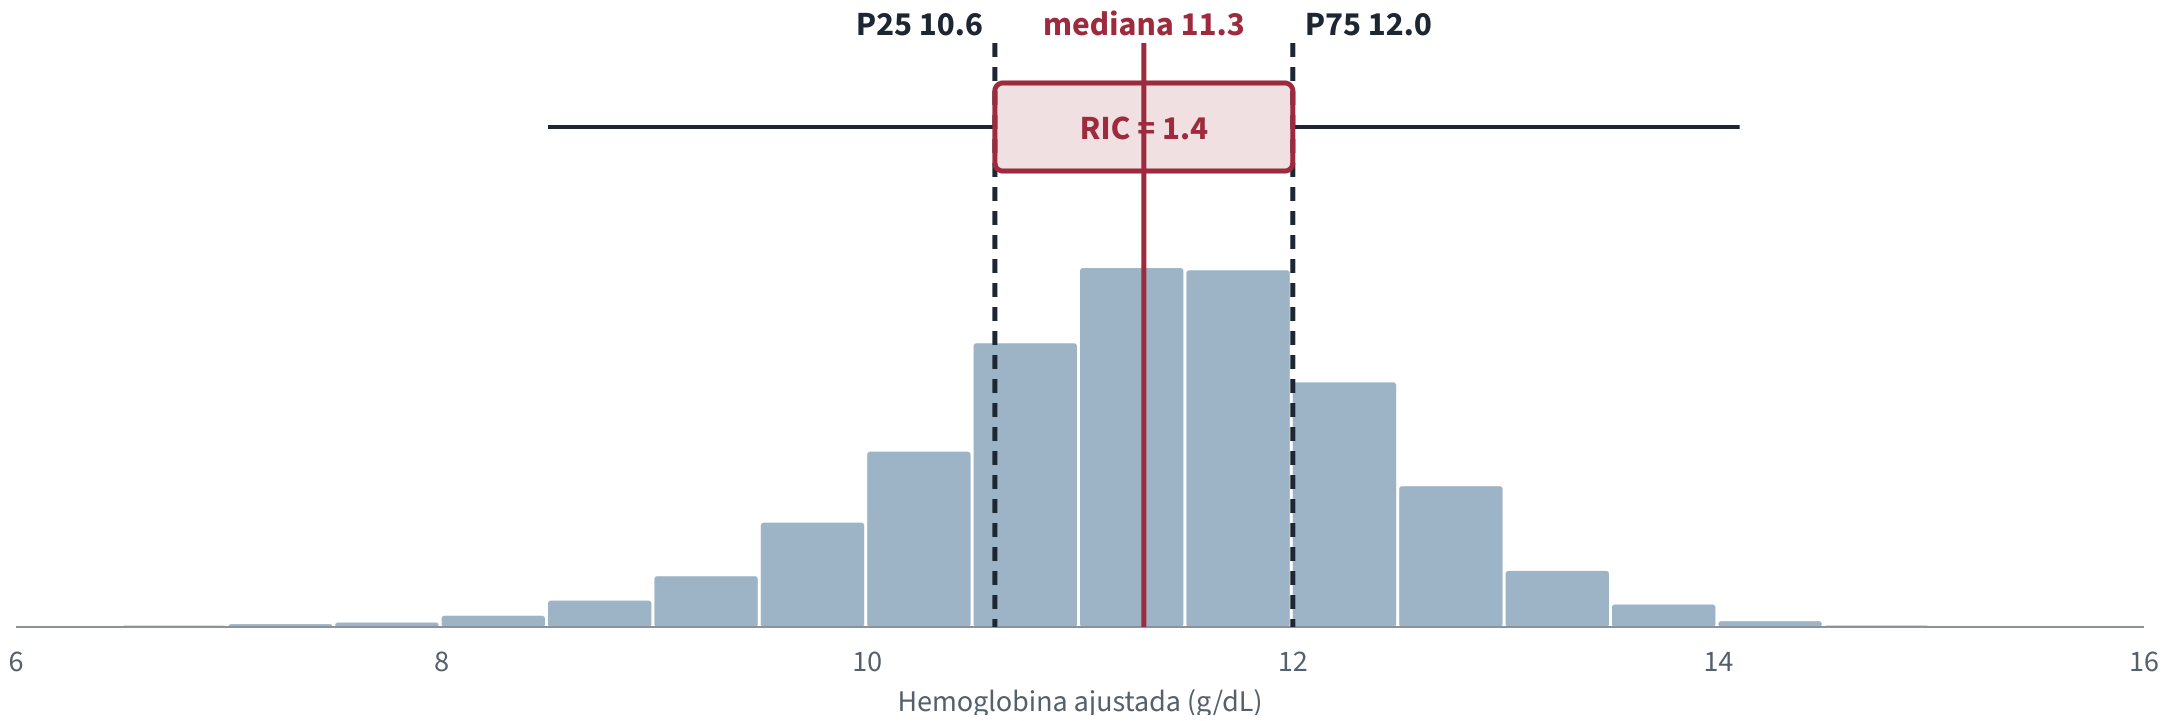
DE
1.08

% bajo 11 g/dL
40.5 %

En una normal, el 68 % cae a ±1 DE de la media y el 95 % a ±2 DE. En la Hb de la ENDES cae el **71.5 %** a ±1 DE: cerca, pero no idéntico. La regla es una guía, no una ley.

PERCENTILES Y RANGO INTERCUARTÍLICO

La caja resume la mitad central

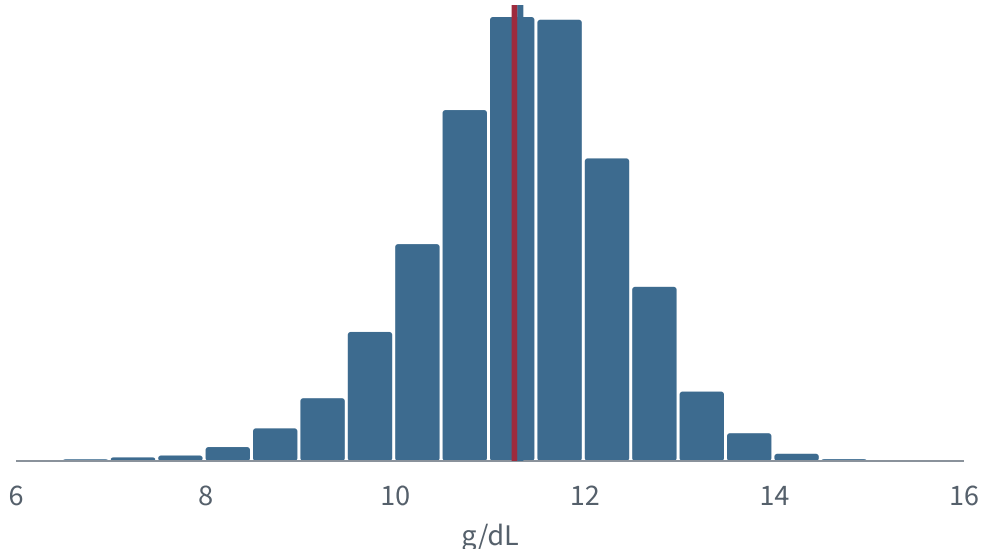


Hemoglobina ajustada, ENDES 2024: P25 = 10.6, mediana = 11.3, P75 = 12.0. **RIC = 1.4 g/dL**. Se reporta como `11.3 [10.6, 12.0]`.

LA FORMA

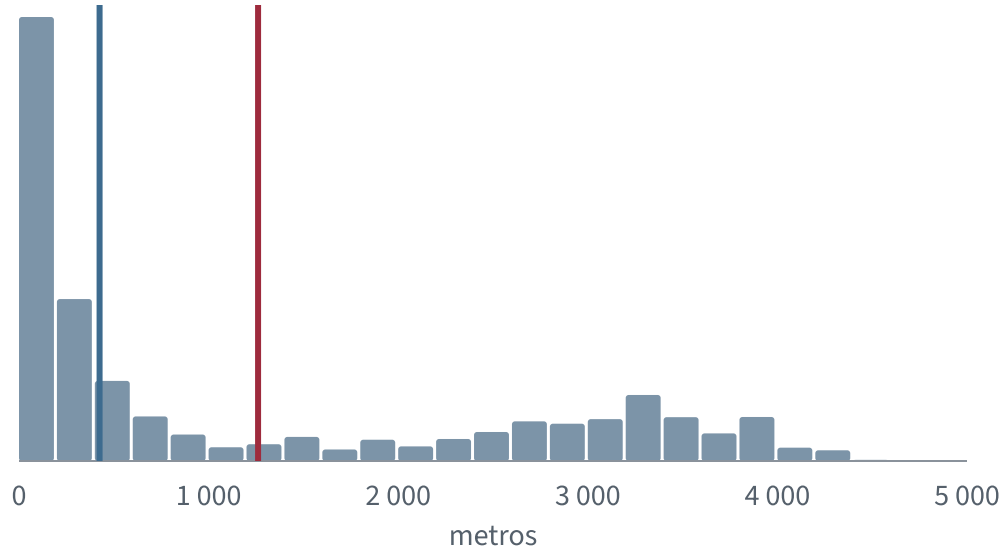
Simétrica contra sesgada

Hemoglobina



Media 11.26 · mediana 11.3: casi iguales.
Reporte **media (DE): 11.3 (1.1)**

Altitud del conglomerado



Media 1 261 m · mediana 425 m · DE 1 407 m.
Reporte **mediana [RIC]: 425 [120, 2 701]**

media mediana

UNA SEÑAL DE ALARMA EN LOS ARTÍCULOS

"Estancia hospitalaria: 5 ± 7 días"

Media menos una DE da −2 días. Nadie se queda menos de cero días.

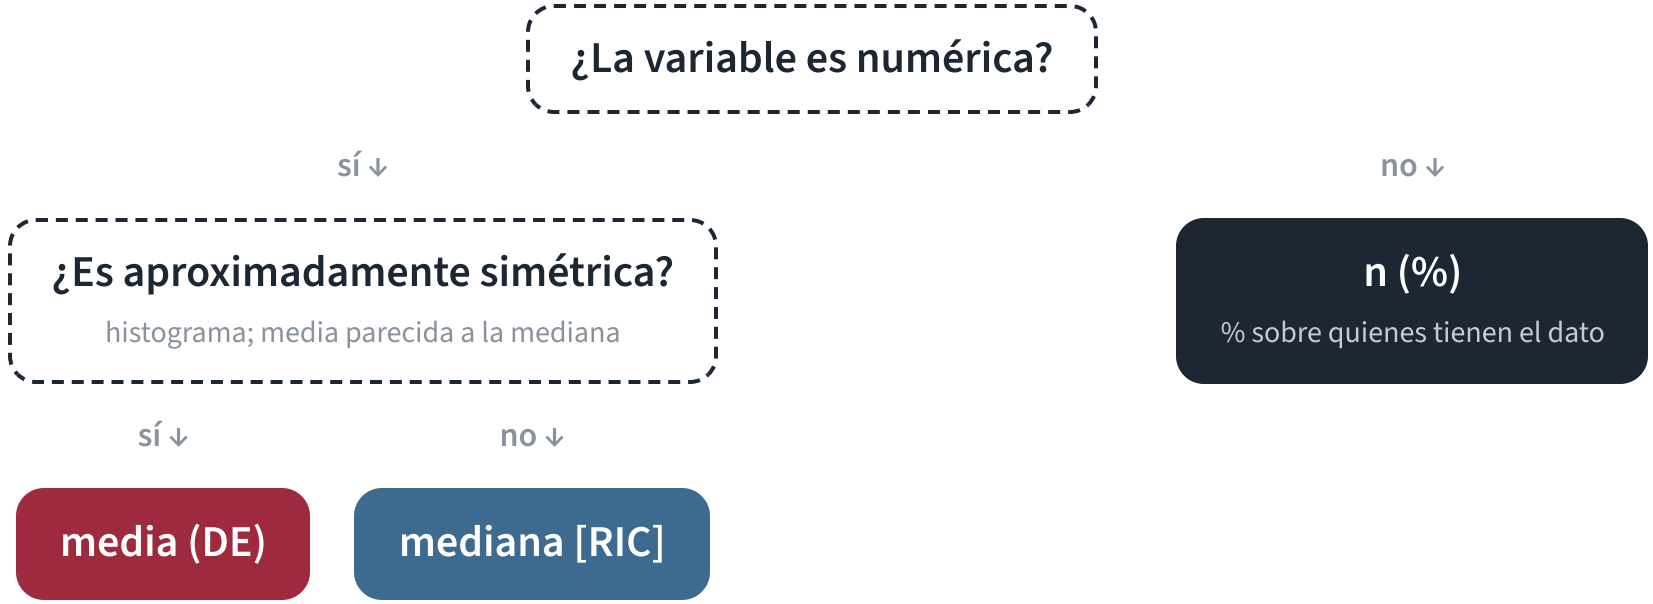
Cuando la DE supera a la media en una variable que no puede ser negativa, la distribución está sesgada y la media (DE) la describe mal.

Casi siempre van con mediana [RIC]

- Días de estancia, de ventilación, de seguimiento
- Creatinina, PCR, troponina, ferritina
- Número de hospitalizaciones o de visitas
- Costos e ingresos

REGLA DE DECISIÓN

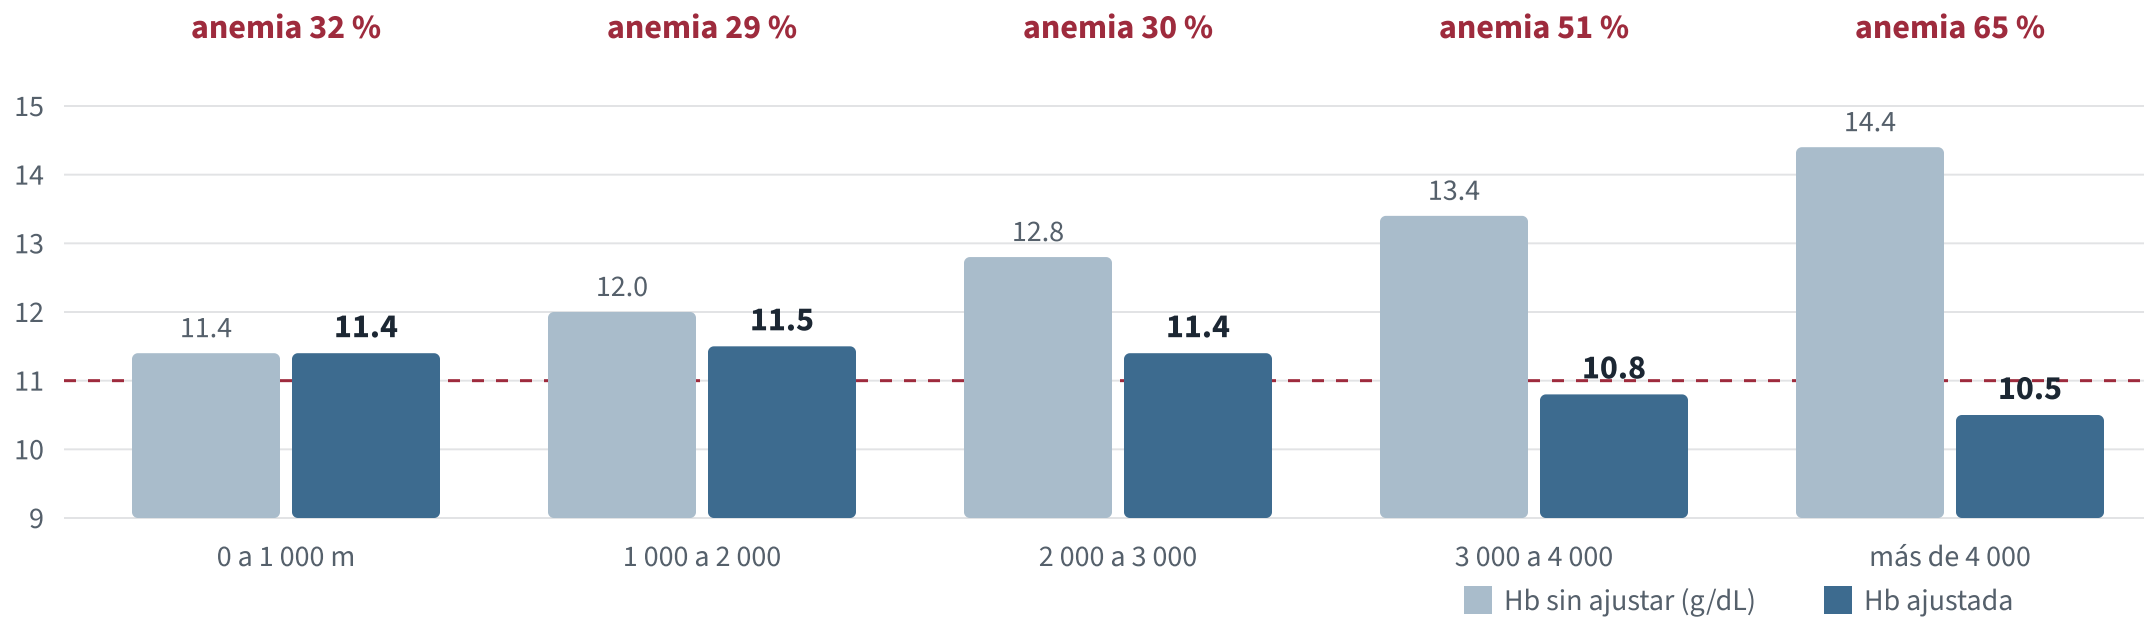
¿Qué resumen va en la tabla?



Mire la figura antes que la prueba de normalidad: con miles de datos, Shapiro-Wilk rechaza casi todo.

UN DETALLE CLÍNICO

La hemoglobina se ajusta por altitud, y el ajuste cambia la prevalencia



Con la guía OMS 2024, que ajusta menos en altura, la anemia de 6 a 35 meses baja de **43.7 %** a **35.3 %**. Misma sangre, otra definición, otra cifra.

ENDES 2024, sin ponderar. Cifra OMS 2024: INEI, Cuadro 6.1 (RM 251-2024-MINSA).

PARTE 4

La tabla 1

Quiénes están en el estudio. La tabla que todos leen primero.

4

PARA QUÉ SIRVE

La tabla 1 responde: ¿a quién se aplica este resultado?

- El lector compara a **sus** pacientes con los del estudio.
- El revisor busca diferencias entre grupos que puedan **confundir** el resultado.
- Todos miran los **faltantes**: un estudio con 40 % sin dato de educación es otro estudio.

STROBE, ítem 14

(a) Características de los participantes (demográficas, clínicas, sociales), exposiciones y posibles confusores.

(b) Número de participantes con datos faltantes en cada variable.

Vandenbroucke JP et al. PLoS Med 2007;4(10):e297. doi:10.1371/journal.pmed.0040297

ANATOMÍA DE UNA TABLA 1 · ENDES 2024

Niñas y niños de 6 a 59 meses según área de residencia

Característica	Total	Rural	Urbana	Faltantes, n (%)
n	18 358	5 663	12 695	
Hemoglobina (g/dL), media (DE)	11.3 (1.1)	11.0 (1.1)	11.4 (1.1)	0
Edad (meses), mediana [RIC]	33 [19, 46]	32 [19, 45]	33 [19, 46]	0
Altitud (m), mediana [RIC]	425 [120, 2 701]	2 073 [312, 3 348]	238 [84, 1 622]	0
Niña, n (%)	9 031 (49.2)	2 809 (49.6)	6 222 (49.0)	0
Quintil de riqueza, n (%)				**0**
Q1 (más pobre)	5 696 (31.0)	4 414 (77.9)	1 282 (10.1)	
Q5 (más rico)	1 553 (8.5)	2 (0.0)	1 551 (12.2)	
Educación de la madre, n (%)				**511 (2.8)**
Primaria o sin nivel	2 874 (16.1)	1 776 (32.5)	1 098 (8.8)	
Superior	2 792 (15.6)	225 (4.1)	2 567 (20.7)	
Anemia, n (%)	6 570 (35.8)	2 505 (44.2)	4 065 (32.0)	0
Desnutrición crónica, n (%)	2 334 (12.7)	1 179 (20.8)	1 155 (9.1)	**52 (0.3)**

n arriba en cada columna.

Simétrica: media (DE), con unidades.

Sesgada: mediana [RIC].

Categórica: n (%), un decimal.

Faltantes: madre que no vive en el hogar.

Sin valores p.

GUÍA PRÁCTICA

Reglas para una tabla 1 útil

- Columnas: los grupos que el estudio compara, más el total.
- Las variables que el lector necesita para juzgar a quién se aplica el resultado, y los posibles confusores.
- Faltantes por variable, en números absolutos.
- Unidades en cada fila; un decimal para porcentajes.
- No incluya la variable que define los grupos (la Hb en una tabla por anemia).
- No cambie de criterio entre filas parecidas sin explicarlo.
- Diga en el título a qué población describe y si usó pesos.

Hayes-Larson E, Kezios KL, Mooney SJ, Lovasi G. Who is in this study, anyway? Guidelines for a useful Table 1. J Clin Epidemiol 2019. doi:10.1016/j.jclinepi.2019.06.011

LA PREGUNTA DE SIEMPRE

¿Por qué no van valores p en la tabla 1?

En un ensayo clínico

Si la aleatorización se hizo bien, toda diferencia al inicio es azar por definición. CONSORT considera innecesario probarla, y Senn mostró que esas pruebas no indican qué variables ajustar.

En un estudio observacional

El valor p dice si una diferencia es compatible con el azar, no si es tan **grande** como para confundir. Con 18 mil niños casi todo da $p < 0.001$; con 40 pacientes, casi nada.

Si necesita cuantificar el desequilibrio, use la **diferencia estandarizada de medias** (`smd=True` en `tableone`). La veremos en la semana 10.

Moher D et al. CONSORT 2010 explanation and elaboration. BMJ 2010;340:c869 · Senn S. Testing for baseline balance in clinical trials. Stat Med 1994;13:1715-26.

PARA REVISAR EN SU PRÓXIMA TESIS

Cinco errores frecuentes

1

Porcentajes con los faltantes en el denominador.

2

54.23817 %: decimales que nadie puede medir.

3

Media (DE) en variables sesgadas: 5 ± 7 días.

4

La variable que define el grupo, dentro de la tabla.

5

Sin n por columna: no se sabe de dónde salen los %.

LA MUESTRA NO ES EL PAÍS

De 46.0 % a 43.7 %: los pesos de muestreo

46.0

Sin pesos. La muestra tiene más niños rurales de los que le tocan.

43.9

Con el peso de cada hogar (`HV005`).

43.7

Con pesos y solo niños que durmieron en la vivienda (*de facto*). **La cifra del INEI.**

La tabla 1 describe a la **muestra**: sin pesos. Una prevalencia del **país** necesita los pesos. Y su intervalo de confianza necesita además estratos y conglomerados (semana 5).

Niños de 6 a 35 meses, ENDES 2024. INEI: 43.7 % nacional, 40.2 % urbano, 51.9 % rural; el cuaderno reproduce las tres cifras.

PARTE 5

Las herramientas

Los paquetes de Python que hacen casi todo el análisis descriptivo.

5

EL ECOSISTEMA

Cinco paquetes, un flujo

leer y limpiar

pandas

Tablas: `read_csv`, `merge`, `groupby`, `describe`.

calcular

numpy

Arreglos y matemáticas: medias, varianzas, percentiles.

forma

scipy.stats

`skew`, `iqr` y, más adelante, las pruebas.

mirar

seaborn

Histogramas y cajas en una línea, sobre matplotlib.

publicar

tableone

La tabla 1 con formato de artículo.

Para explorar rápido existen reportes automáticos (`ydata-profiling`, `skimpy`). Sirven para mirar, no para publicar: no saben qué es un 999.

PANDAS PARA EDA

Diez líneas que va a usar siempre

```
df.shape                                    # filas y columnas: ¿qué es una fila?
df.head()                                   # mirar antes de calcular
df.dtypes                                   # tipos de almacenamiento, no estadísticos
df.describe()                               # min y max primero: ¿hay 999?
df["x"].value_counts(dropna=False)           # categorías y códigos
df.isna().sum()                             # faltantes reales
df.merge(otra, on="id", validate="many_to_one")
df.groupby("area")["hb"].agg(["mean", "std", "median"])
pd.cut(df["altitud"], bins=[0, 1000, 2000, 3000, 4000, 5500])
pd.Categorical(x, categories=[...], ordered=True)   # ordinales en orden
```

NUMPY Y TABLEONE

De la fórmula al artículo

numpy: la fórmula a mano

```
hb = muestra["hb"].to_numpy()
hb.mean()                    # 11.26
np.median(hb)                # 11.3
hb.std(ddof=1)               # 1.08
np.percentile(hb, [25, 75]) # 10.6, 12.0
```

tableone: la tabla publicable

```
%pip install -q tableone
from tableone import TableOne

TableOne(muestra,
    columns=["edad_meses", "hb", "sexo"],
    categorical=["sexo"],
    nonnormal=["edad_meses"],
    groupby="area", missing=True)
```

Pollard TJ et al. JAMIA Open 2018;1(1):26-31. doi:10.1093/jamiaopen/ooy012

AHORA, AL CUADERNO

Abra el cuaderno de la semana 2

Archivo → Guardar una copia en Drive. Ejecute de arriba hacia abajo con Shift + Enter.

`nielspac177.github.io/curso-datos-medicina/materiales/#s2`

CIERRE

Antes de publicar una tabla 1

- Sé qué es una fila y cuántas quedan en cada paso.
- Busqué códigos (9, 99, 999) y valores imposibles.
- Los faltantes son NaN y los reporto.
- Cada variable tiene su tipo y su resumen.
- Las ordinales están en orden.
- La primera fila dice el n de cada columna.
- No incluí la variable que define el grupo ni valores p.
- Si comparo con el país, usé los pesos.

Semana 3: dibujaremos estos mismos datos. Piense qué figura mostraría mejor la relación entre altitud, hemoglobina y anemia.

PARA SEGUIR

Recursos

- **Simuladores interactivos** de media, mediana y dispersión (Online Statistics Education, dominio público): onlinestatbook.com.
- **Seeing Theory** (Brown University): esperanza y varianza, animadas. seeing-theory.brown.edu
- **OpenIntro Statistics**, capítulo 2 (CC BY-SA): openintro.org/book/os

- Hayes-Larson et al. Guidelines for a useful Table 1. J Clin Epidemiol 2019. doi
- Vandenbroucke et al. STROBE explanation and elaboration. PLoS Med 2007. doi
- Pollard et al. tableone. JAMIA Open 2018. doi
- INEI. Indicadores de resultados de los programas presupuestales, ENDES 2024.