

# Estadística y Machine Learning para Estudiantes de Medicina

## con Bases de Datos Abiertas en Salud

Curso en vivo de 16 semanas · Proyecto sin fines de lucro · Dr. Niels Pacheco-Barrios · Cohorte fundadora (Perú) · Domingos de 8:00 a 10:00 p. m. (hora Perú) · Inicio: por anunciar

|                    |                                                                                                                       |
|--------------------|-----------------------------------------------------------------------------------------------------------------------|
| Dirigido a         | Estudiantes de medicina y de carreras de la salud. No se requiere experiencia en programación ni en estadística.      |
| Duración           | 16 semanas (un semestre) · 32 horas de clase en vivo + trabajo en grupo                                               |
| Clases             | Domingos de 8:00 a 10:00 p. m., hora Perú, en vivo (cada sesión queda grabada) + 1 a 2 horas de trabajo asincrónico   |
| Modalidad          | Virtual, en cohorte, con grupos pequeños de trabajo (pods de 4 a 6 estudiantes) y proyecto final                      |
| Herramientas       | Python en Google Colab (gratuito, en la nube, sin instalación) + asistentes de inteligencia artificial para programar |
| Preparación previa | Videos breves de preparación antes de cada clase (aula invertida)                                                     |
| Certificado        | Constancia digital que consigna las horas y el título del proyecto final                                              |
| Contribución       | Donación simbólica: S/ 85 mensuales o S/ 299 única (proyecto sin fines de lucro)                                      |

### Descripción del curso

La medicina genera más datos que nunca; sin embargo, la formación de pregrado rara vez enseña a analizarlos. Este curso aborda esa brecha en un semestre: parte de la estadística desde cero y llega hasta los fundamentos del machine learning, con práctica semanal sobre bases de datos abiertas reales (MIMIC-IV, PPMI, NHANES, ENDES, SINADEF) en lugar de ejemplos simplificados diseñados para la enseñanza.

La metodología combina tres componentes. Primero, el aula invertida: antes de cada sesión, un video breve presenta la intuición del tema, sin formalismo innecesario. Segundo, una clase semanal en vivo de dos horas, en la que el docente desarrolla el concepto con ejemplos médicos y lo aplica en un cuaderno de Google Colab que cada estudiante ejecuta y modifica en paralelo. Tercero, los pods: grupos de 4 a 6 estudiantes que resuelven juntos los retos semanales y desarrollan el proyecto final con mentoría del docente.

Al concluir, cada estudiante habrá completado un análisis íntegro con una base de datos abierta, desde el dato crudo hasta una presentación en formato de congreso, y contará con las bases para el paso siguiente: la publicación.

### Objetivos de aprendizaje

Al finalizar el curso, el estudiante será capaz de:

- Manejar Python en Google Colab para importar, limpiar, describir y graficar datos de salud.
- Comprender e interpretar los conceptos centrales de la estadística: distribuciones, intervalos de confianza, valores p y poder estadístico.
- Elegir y ejecutar las pruebas estadísticas de uso más frecuente en investigación médica y leerlas críticamente en un artículo.
- Ajustar e interpretar regresiones lineales y logísticas, incluyendo el manejo básico de confusores.
- Entrenar y evaluar modelos de machine learning (árboles, random forest, gradient boosting) y explicar el funcionamiento de las redes neuronales.
- Acceder a bases de datos abiertas de salud y completar con ellas un proyecto presentado en formato de congreso.

## Bases de datos del curso

---

- **MIMIC-IV** (PhysioNet): historias clínicas de cuidados intensivos de un hospital de Harvard. Se trabaja con la versión de demostración abierta y se orienta el proceso de credenciamiento (curso CITI) para acceder a la versión completa.
- **PPMI** (Parkinson's Progression Markers Initiative): estudio longitudinal de la enfermedad de Parkinson con datos clínicos, biomarcadores y neuroimagen; acceso gratuito previa solicitud.
- **Catálogo neuro2.ai** (datasets.neuro2.ai): índice interactivo de más de 1,000 datasets abiertos de neurociencia, con búsqueda por modalidad y fuente; de este catálogo provendrán muchas de las bases de los proyectos finales.
- **NHANES**: encuesta nacional de salud y nutrición de los EE. UU., con examen físico y de laboratorio.
- **ENDES** (INEI, Perú): salud materno-infantil, anemia e hipertensión.
- **SINADEF** (Perú): registro nacional de defunciones con causas.
- **Global Burden of Disease** (IHME): carga de enfermedad por país, edad y sexo.

### Módulo 0: nivelación (opcional, autoguiado)

Disponible desde la inscripción, prepara al estudiante para la semana 1. Consta de cuatro lecciones breves, cada una con video y un cuaderno de Colab: notación matemática y funciones; logaritmos y odds; vectores y matrices como tablas de datos; y probabilidad básica. No incluye demostraciones formales: se limita a la intuición necesaria para seguir el curso. Quien ya domine estos temas puede omitirlo.

## Programación asistida por inteligencia artificial

---

El curso enseña a programar como se programa en la práctica actual: con un asistente de inteligencia artificial. Desde la semana 1 se emplean los asistentes disponibles (Gemini integrado en Colab, ChatGPT, Claude) para escribir, explicar y depurar código, con formación explícita en tres destrezas: formular instrucciones precisas, verificar lo que el asistente devuelve y detectar sus errores. Incluye una demostración de Claude Code, el agente de programación de Anthropic, automatizando un análisis completo de principio a fin. El principio rector del curso es que el asistente colabora en el código, mientras que la pregunta, la verificación y la interpretación corresponden al estudiante.

## Calendario de 16 semanas

| Semana y tema                            | Clase en vivo                                                                                     | Video de preparación                                  | Práctica con datos                                                  |
|------------------------------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------|---------------------------------------------------------------------|
| <b>1. El médico y los datos</b>          | Por qué aprender a analizar datos; panorama del curso; primeros pasos en Google Colab y Python    | Las ideas centrales de la estadística                 | Explorar una tabla de NHANES y elaborar el primer gráfico           |
| <b>2. Describir datos</b>                | Tipos de variables; media, mediana y dispersión; la tabla 1 de un estudio                         | Media, varianza y desviación estándar                 | Construir una tabla 1 con ENDES                                     |
| <b>3. Visualizar datos</b>               | Principios de una buena figura; histogramas, cajas y dispersión; errores comunes en los artículos | Histogramas y diagramas de caja                       | Reproducir y mejorar figuras de un artículo con datos de GBD        |
| <b>4. Probabilidad y distribuciones</b>  | Probabilidad para médicos; distribución normal y binomial; teorema del límite central             | La distribución normal; el teorema del límite central | Simular muestras y observar el teorema en acción                    |
| <b>5. Estimar con confianza</b>          | Muestras y poblaciones; error estándar; intervalos de confianza; bootstrap                        | Error estándar; intervalos de confianza; bootstrap    | Intervalos de confianza para prevalencias con ENDES                 |
| <b>6. El valor p</b>                     | Hipótesis nula; qué significa (y qué no) un valor p; poder estadístico y tamaño de muestra        | El valor p; poder estadístico                         | Simular estudios con y sin poder suficiente                         |
| <b>7. Pruebas estadísticas</b>           | t de Student, Mann-Whitney, chi cuadrado; pruebas pareadas; comparaciones múltiples y FDR         | Prueba t; chi cuadrado; comparaciones múltiples       | Comparar grupos en NHANES y corregir comparaciones múltiples        |
| <b>8. Correlación y regresión lineal</b> | Correlación no es causalidad; recta de mínimos cuadrados; R cuadrado. Entrega del mini proyecto 1 | Regresión lineal; R cuadrado                          | Mini proyecto 1: pregunta descriptiva con NHANES o ENDES            |
| <b>9. Regresión logística</b>            | Odds y odds ratio; el modelo logístico; interpretación clínica de coeficientes                    | Odds y regresión logística                            | Mortalidad en UCI con la demo de MIMIC-IV                           |
| <b>10. Confusión y ajuste</b>            | Confusores y regresión múltiple; introducción a los grafos causales (DAGs); lectura crítica       | Regresión múltiple                                    | MIMIC-IV: ajustar por gravedad y comorbilidad y comparar resultados |

| Semana y tema                             | Clase en vivo                                                                                                               | Video de preparación                 | Práctica con datos                                                                     |
|-------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|--------------------------------------|----------------------------------------------------------------------------------------|
| <b>11. Del modelo al machine learning</b> | Qué cambia entre inferencia y predicción; sesgo y varianza; entrenamiento, prueba y validación cruzada                      | Sesgo y varianza; validación cruzada | Primer modelo predictivo con MIMIC-IV                                                  |
| <b>12. Árboles y bosques</b>              | Árboles de decisión; random forest; importancia de variables                                                                | Árboles de decisión y random forest  | Predecir progresión de enfermedad con datos de PPMI                                    |
| <b>13. Gradient boosting y evaluación</b> | XGBoost en intuición; métricas: sensibilidad, especificidad, ROC, calibración                                               | Gradient boosting; curvas ROC        | Comparar modelos en PPMI y elegir con criterio clínico                                 |
| <b>14. Redes neuronales</b>               | La neurona artificial; capas y retropropagación en intuición; cuándo usarlas (y cuándo no) en salud                         | Redes neuronales y retropropagación  | Probar una red simple y compararla con el modelo clásico                               |
| <b>15. Taller de proyecto</b>             | Trabajo en pods con asesoría del docente; análisis y armado de la presentación                                              | (semana de proyecto)                 | Proyecto final: base elegida por el pod (catálogo neuro2.ai, PhysioNet, NHANES, ENDES) |
| <b>16. Presentaciones finales</b>         | Presentación en formato de congreso de cada pod; retroalimentación; la ruta a seguir: publicación y congresos estudiantiles | (cierre)                             | Presentación final y entrega del reporte                                               |

## Evaluación

| Componente                                      | Peso |
|-------------------------------------------------|------|
| Participación y retos semanales en pod          | 30 % |
| Cuestionarios cortos de los videos preclase     | 20 % |
| Mini proyecto 1 (semana 8)                      | 20 % |
| Proyecto final y presentación (semanas 15 y 16) | 30 % |

Aprueban quienes alcanzan el 60 % del puntaje y presentan el proyecto final. La constancia digital consigna las 32 horas de clase en vivo, las horas asincrónicas y el título del proyecto.

## Contribución · proyecto sin fines de lucro (cohorte fundadora, Perú)

### **S/ 85 al mes** durante los cuatro meses del curso

Este curso es un proyecto sin fines de lucro. El precio suele ser la principal barrera para estudiantes de medicina que aún no trabajan; por ello no se cobra un precio de mercado (programas internacionales equivalentes cuestan entre US\$ 800 y varios miles de dólares), sino una donación simbólica que permite al docente dedicar tiempo al curso y sostener la plataforma y las becas. Precio exclusivo de la primera cohorte. También puede optar por una donación única de **S/ 299** por todo el curso.

- Donación por Plin al 993 126 398 (Niels Pacheco-Barrios). La inscripción queda confirmada con el formulario y la primera donación (S/ 85 del primer mes, o S/ 299 única).
- Vacantes limitadas: 40 estudiantes (pods de 4 a 6).
- Becas parciales disponibles: formulario simple de 5 minutos.
- Garantía: devolución completa hasta el final de la semana 2 para quien decida no continuar.
- La cohorte fundadora conserva este precio en los siguientes cursos del programa.

## Requisitos

---

- Computadora con navegador y conexión estable a internet (todo el software es gratuito y en la nube).
- Cuenta de Google para usar Google Colab.
- Inglés básico para algunos videos de preparación (cuentan con subtítulos; las guías del curso están en español).
- Disponibilidad de 3 a 4 horas semanales en total.

## Políticas del curso

---

- **Asistencia:** las clases quedan grabadas; no obstante, el trabajo en pod requiere participación en vivo en al menos 12 de las 16 semanas.
- **Integridad académica:** los análisis del proyecto son del equipo; se cita toda fuente y todo código reutilizado.
- **Uso de inteligencia artificial:** permitido como asistente de programación, con declaración de uso; los cuestionarios y la interpretación de resultados son individuales.

## Bibliografía y recursos

---

- Videos y guías ilustradas de preparación, asignados semana a semana en el aula virtual.
- Diez DM, Barr CD, Cetinkaya-Rundel M. *OpenIntro Statistics* (gratuito, [openintro.org](https://openintro.org)).
- Cuadernos de Google Colab del curso, entregados cada semana.

## Sobre el docente

---

Médico cirujano por la Universidad Peruana Cayetano Heredia. Magíster en Estadística por la Harvard Medical School (EE. UU.). Investigador postdoctoral en el Brigham and Women's Hospital (Harvard). Colaborador de MIT Critical Data y del curso Machine Learning for Healthcare del MIT. Investiga con las mismas bases de datos abiertas que se emplean en el curso (MIMIC-IV, NIS, NSQIP, PPMI), con publicaciones en revistas internacionales indexadas.

**Inscripciones y consultas:** WhatsApp +51 993 126 398 (Dr. Niels Pacheco-Barrios)

Inscripción: complete el formulario del curso y realice la primera donación por Plin al 993 126 398. La confirmación se envía por WhatsApp en un plazo máximo de 24 horas.