

Estadística y Machine Learning para Estudiantes de Medicina

con Bases de Datos Abiertas en Salud

Curso en vivo de 16 semanas · Dr. Niels Pacheco-Barrios · Cohorte fundadora (solo Perú) · Domingos 8:00 a 10:00 p. m. (hora Perú) · Inicio: por anunciar

Dirigido a	Estudiantes de medicina y de carreras de la salud. No se requiere experiencia en programación ni en estadística.
Duración	16 semanas (un semestre) · 32 horas de clase en vivo + trabajo en grupo
Clases	Domingos de 8:00 a 10:00 p. m., hora Perú, en vivo (queda grabada) + 1 a 2 horas de trabajo asincrónico
Modalidad	Virtual, en cohorte, con grupos pequeños de trabajo (pods de 4 a 6) y proyecto final
Herramientas	Python en Google Colab (gratuito, en la nube, sin instalar nada) + asistentes de inteligencia artificial para programar
Preparación previa	Videos cortos de preparación antes de cada clase (aula invertida)
Certificado	Constancia digital con horas y título del proyecto final

¿De qué trata el curso?

La medicina produce más datos que nunca, pero la formación del pregrado casi no enseña a analizarlos. Este curso lo enseña en un semestre: aprendes estadística desde cero y llegas hasta los fundamentos del machine learning, practicando cada semana con bases de datos abiertas reales (MIMIC-IV, PPMI, NHANES, ENDES, SINADEF) en lugar de ejemplos de juguete.

El método combina tres piezas. Primero, aula invertida: antes de cada clase ves un video corto que te deja la intuición del tema, sin fórmulas de más. Segundo, una clase semanal en vivo de 2 horas donde el docente profundiza el concepto con ejemplos médicos y lo aplica en un cuaderno de Google Colab que ejecutas y modificas en paralelo. Tercero, pods: grupos de 4 a 6 estudiantes que resuelven los retos semanales juntos y desarrollan el proyecto final con mentoría.

Al terminar habrás hecho un análisis completo con una base de datos abierta, del dato crudo a una presentación tipo congreso, y tendrás las bases para el siguiente paso: publicar.

Objetivos de aprendizaje

Al finalizar el curso serás capaz de:

- Manejar Python en Google Colab para importar, limpiar, describir y graficar datos de salud.
- Comprender e interpretar los conceptos centrales de la estadística: distribuciones, intervalos de confianza, valores p, poder estadístico.
- Elegir y ejecutar las pruebas estadísticas de uso más frecuente en investigación médica y leerlas críticamente en un artículo.
- Ajustar e interpretar regresiones lineales y logísticas, incluyendo el manejo básico de confusores.
- Entrenar y evaluar modelos de machine learning (árboles, random forest, gradient boosting) y explicar qué hacen las redes neuronales.

- Acceder a bases de datos abiertas de salud y completar con ellas un proyecto presentado en formato de congreso.
- ### Las bases de datos con las que trabajarás
- **MIMIC-IV** (PhysioNet): historias clínicas de cuidados intensivos de un hospital de Harvard. Trabajamos con la versión demo abierta y te guiamos en el credenciamiento (curso CITI) para acceder a la versión completa.
 - **PPMI** (Parkinson's Progression Markers Initiative): estudio longitudinal de Parkinson con datos clínicos, biomarcadores y neuroimagen; acceso gratuito por solicitud.
 - **Catálogo neuro2.ai** (datasets.neuro2.ai): índice interactivo de más de 1,000 datasets abiertos de neurociencia, buscable por modalidad y fuente; de aquí saldrán muchas de las bases de los proyectos finales.
 - **NHANES**: encuesta nacional de salud y nutrición de EE. UU., con examen físico y laboratorio.
 - **ENDES** (INEI, Perú): salud materno-infantil, anemia, hipertensión.
 - **SINADEF** (Perú): registro nacional de defunciones con causas.
 - **Global Burden of Disease** (IHME): carga de enfermedad por país, edad y sexo.

Módulo 0: nivelación (opcional, autoguiado)

Disponible desde la inscripción, para llegar cómodo a la semana 1. Son 4 lecciones cortas con video y un cuaderno de Colab: notación matemática y funciones; logaritmos y odds; vectores y matrices vistos como tablas de datos; y probabilidad básica. Nada de demostraciones: solo la intuición necesaria para seguir el curso sin fricción. Quien ya se siente cómodo puede saltarlo.

Programación asistida por inteligencia artificial

En el curso programarás como se programa hoy: con un asistente de IA al lado. Desde la semana 1 usamos los asistentes disponibles (Gemini integrado en Colab, ChatGPT, Claude) para escribir, explicar y depurar código, y te enseñamos lo que separa al que copia del que entiende: cómo pedir bien, cómo verificar lo que la IA devuelve y cómo detectar cuándo se equivoca. Incluye una demostración de Claude Code, el agente de programación de Anthropic, automatizando un análisis completo de principio a fin. La regla del curso es simple: la IA escribe código contigo; la pregunta, la verificación y la interpretación son tuyas.

Calendario de 16 semanas

Semana y tema	Clase en vivo	Video de preparación	Práctica con datos
1. El médico y los datos	Por qué aprender a analizar datos; panorama del curso; primeros pasos en Google Colab y Python	Las ideas centrales de la estadística	Explorar una tabla de NHANES y hacer tu primer gráfico
2. Describir datos	Tipos de variables; media, mediana y dispersión; la tabla 1 de un estudio	Media, varianza y desviación estándar	Construir una tabla 1 con ENDES
3. Visualizar datos	Principios de una buena figura; histogramas, cajas y dispersión; errores comunes en papers	Histogramas y diagramas de caja	Reproducir y mejorar figuras de un artículo con datos de GBD

4. Probabilidad y distribuciones	Probabilidad para médicos; distribución normal y binomial; teorema del límite central	La distribución normal; el teorema del límite central	Simular muestras y ver el teorema en acción
5. Estimar con confianza	Muestras y poblaciones; error estándar; intervalos de confianza; bootstrap	Error estándar; intervalos de confianza; bootstrap	Intervalos de confianza para prevalencias con ENDES
6. El valor p	Hipótesis nula; qué significa (y qué no) un valor p; poder estadístico y tamaño de muestra	El valor p; poder estadístico	Simular estudios con y sin poder suficiente
7. Pruebas estadísticas	t de Student, Mann-Whitney, chi cuadrado; pruebas pareadas; comparaciones múltiples y FDR	Prueba t; chi cuadrado; comparaciones múltiples	Comparar grupos en NHANES y corregir comparaciones múltiples
8. Correlación y regresión lineal	Correlación no es causalidad; recta de mínimos cuadrados; R cuadrado. Entrega del mini proyecto 1	Regresión lineal; R cuadrado	Mini proyecto 1: pregunta descriptiva con NHANES o ENDES
9. Regresión logística	Odds y odds ratio; el modelo logístico; interpretación clínica de coeficientes	Odds y regresión logística	Mortalidad en UCI con la demo de MIMIC-IV
10. Confusión y ajuste	Confusores y regresión múltiple; introducción a los grafos causales (DAGs); lectura crítica	Regresión múltiple	MIMIC-IV: ajustar por gravedad y comorbilidad y comparar resultados
11. Del modelo al machine learning	Qué cambia entre inferencia y predicción; sesgo y varianza; entrenamiento, prueba y validación cruzada	Sesgo y varianza; validación cruzada	Primer modelo predictivo con MIMIC-IV
12. Árboles y bosques	Árboles de decisión; random forest; importancia de variables	Árboles de decisión y random forest	Predecir progresión de enfermedad con datos de PPMI
13. Gradient boosting y evaluación	XGBoost en intuición; métricas: sensibilidad, especificidad, ROC, calibración	Gradient boosting; curvas ROC	Comparar modelos en PPMI y elegir con criterio clínico
14. Redes neuronales	La neurona artificial; capas y retropropagación en intuición; cuándo usarlas (y cuándo no) en salud	Redes neuronales y retropropagación	Probar una red simple y compararla con el modelo clásico
15. Taller de proyecto	Trabajo en pods con asesoría del docente; análisis y armado de la presentación	(semana de proyecto)	Proyecto final: base elegida por el pod (catálogo neuro2.ai, PhysioNet, NHANES, ENDES)
16. Presentaciones finales	Presentación tipo congreso de cada pod; retroalimentación; cómo seguir: publicación y congresos estudiantiles	(cierre)	Presentación final y entrega del reporte

Evaluación

Componente	Peso
Participación y retos semanales en pod	30 %
Cuestionarios cortos de los videos pre-clase	20 %
Mini proyecto 1 (semana 8)	20 %
Proyecto final y presentación (semanas 15 y 16)	30 %

Aprueban quienes alcanzan el 60 % del puntaje y presentan el proyecto final. La constancia digital indica las 32 horas de clase en vivo, las horas asincrónicas y el título del proyecto.

Contribución (cohorte fundadora, Perú)

S/ 85 al mes durante los 4 meses del curso

Programas internacionales equivalentes se venden entre US\$ 800 y varios miles de dólares. Esta cohorte funciona por contribución: tu aporte sostiene el proyecto y las becas. Exclusivo de la primera cohorte. ¿Prefieres dejarlo resuelto? Aporte único de **S/ 299** por todo el curso.

- Aporte por Plin al 993 126 398 (Niels Pacheco-Barrios). Tu inscripción queda confirmada con el formulario y el primer aporte (S/ 85 del primer mes, o S/ 299 único).
- Cupos limitados: 40 estudiantes (pods de 4 a 6).
- Becas parciales disponibles: formulario simple de 5 minutos.
- Garantía: si el curso no es para ti, devolución completa hasta el final de la semana 2.
- La cohorte fundadora conserva este precio en los siguientes cursos del programa.

Requisitos

- Computadora con navegador y conexión estable a internet (todo el software es gratuito y en la nube).
- Cuenta de Google para usar Google Colab.
- Inglés básico para algunos videos de preparación (tienen subtítulos; las guías del curso están en español).
- Compromiso de 3 a 4 horas semanales en total.

Políticas del curso

- **Asistencia:** las clases quedan grabadas, pero el trabajo en pod requiere participación en vivo en al menos 12 de las 16 semanas.
- **Integridad:** los análisis del proyecto son del equipo; se cita toda fuente y todo código reutilizado.
- **Uso de inteligencia artificial:** permitido como asistente para programar, declarándolo; los cuestionarios y la interpretación de resultados son individuales.

Bibliografía y recursos

- Videos y guías ilustradas de preparación, asignados semana a semana en el aula virtual.
- Diez DM, Barr CD, Cetinkaya-Rundel M. *OpenIntro Statistics* (gratuito, openintro.org).
- Cuadernos de Google Colab del curso, entregados cada semana.

Sobre el docente

Médico cirujano por la Universidad Peruana Cayetano Heredia. Magíster en Estadística por la Harvard Medical School (EE. UU.). Investigador postdoctoral en el Brigham and Women's Hospital (Harvard). Colaborador de MIT Critical Data y del curso Machine Learning for Healthcare del MIT. Investiga con las mismas bases de datos abiertas que usarás en el curso (MIMIC-IV, NIS, NSQIP, PPMI), con publicaciones en revistas internacionales indexadas.

Inscripciones y consultas: WhatsApp +51 993 126 398 (Dr. Niels Pacheco-Barrios)

Inscripción: completa el formulario del curso y realiza el primer pago por Plin al 993 126 398. Te confirmamos por WhatsApp en menos de 24 horas.